

统计分析方案

GUARDIAN-A8：儿科生成式医学 AI 中人机监督与临床自主权边界的专家裁决二级分析

字段	最终定稿
SAP 版本	FINAL v2.0
锁定日期	2026-07-16
注册定位	固定语料、事后探索性二级分析；在 A8 特异性最终建模、图表生成和论文 claim 锁定前定稿
主分析集	A8 Core：12 个场景，12 个模型，144 条模型-场景回答
敏感性分析集	A8 Extended：24 个场景，288 条模型-场景回答
主要证据等级	描述性估计 + 预设稳健性分析；复杂分层模型仅作支持性探索
GitHub 用途	可作为公开注册型 SAP 上传；配套 JSON 审计文件记录数据结构与可行性核查

1. 最终统计师核查意见

定稿结论 现有 GUARDIAN 数据足以支持一个高水平、透明、可注册的 A8 探索性二级分析；但最强证据应来自锁定数据的描述性估计、模型层精确置换和预设敏感性分析，而不是把 144 条回答视为独立样本的复杂显著性检验。
--

科学性判断：A8 的研究问题具有明确临床价值，即生成式医学 AI 在人机监督、患者自主权、权限边界、沟通责任和审计责任上的失校准是否可以被外化、测度和校准。该问题与 VIM 关于“使临床 AI 中隐含价值权衡可见”的核心论述一致，也与 GUARDIAN 的 value-boundary 框架相吻合。

可行性判断：数据结构完整，636 条最终判定均可链接模型、场景和域；A8 Core 有 144 条回答、32 个最终失败和 24 个第三轮裁决。这个规模足以支持主要描述性分析和审计型报告，但不足以把域级比较、单模型排名或普通混合模型 p 值作为主结论。

v2.0 相比 v1.0 的关键修订：将主证据从复杂模型前移到描述性估计；加入模型层精确置换作为类别比较的稳健方法；预设混合模型收敛失败、准分离和小簇数量的处理；明确新增机制编码变量不属于当前已锁定数据的可支持终点。

2. 注册定位与报告规范

本 SAP 是对已完成专家裁决数据的二级分析方案，不是临床试验方案，也不是新增模型开发或真实临床部署评价。注册时应如实标注为 **post-hoc exploratory secondary analysis of a fixed, previously adjudicated benchmark corpus**。

规范/框架	本研究中的使用方式	适用性判断
STROBE	用于观察性、横断面式固定语料评价的基本透明报告框架。	主参照
AI/ML reporting guidance	用于补足模型、任务、数据锁定、可重复性和人类评价流程透明度。	主参照
TRIPOD-LLM / TRIPOD+AI	借鉴 LLM/AI 评价透明度、任务定义和不确定性报告；不把本研究写成预测模型开发研究。	部分借鉴
DECIDE-AI	强调早期临床 AI 评价中的人因、安全和工作流透明度；本研究不是 live clinical evaluation 。	概念借鉴，不硬套
CONSORT-AI / SPIRIT-AI	适用于 AI 干预临床试验报告或方案。	不适用
VIM	作为价值权衡可见化的理论背景，支持 A8 value-boundary 的外化与测度。	理论参照

3. 研究问题与目标

总体研究问题：在儿科生成式医学 AI 语境中，人机监督与临床自主权边界是否可以作为一种可测量的 **value-boundary miscalibration** 维度，并通过专家最终裁决、裁决负担和既有失败表型加以刻画？

- 主要目标：估计 A8 Core 中专家最终裁决失败的发生比例和不确定性。
- 关键次要目标：估计第三轮裁决需求，作为 **contested human-oversight value-boundary** 的代理指标。
- 探索性目标：比较 **general foundation** 与 **medical vertical** 模型在 A8 Core 和 A8 Extended 中的失败/裁决模式。
- 机制性描述目标：使用既有 **failure phenotype** 描述 A8 失败回答中 **unsafe accommodation/sycophancy** 与 **defensive evasion/mechanical refusal** 的相对结构。

4. 数据来源、分析单位与分析集

分析单位为单个 **model-scenario response**。数据具有交叉结构：每个场景由 12 个模型回答，每个模型覆盖 53 个场景。因此，所有模型分析必须考虑 **scenario** 与 **model** 的聚类或配对结构；不得把 636 条或 144 条回答简单视为独立观测。

分析集	场景	模型	回答	最终失败	第三轮裁决
Overall GUARDIAN	53	12	636	196/636 (30.8%; Wilson 95% CI 27.4-34.5%)	166/636 (26.1%)
A8 Core	12	12	144	32/144 (22.2%; Wilson 95% CI 16.2-29.7%)	24/144 (16.7%)
A8 Extended	24	12	288	92/288 (31.9%; Wilson 95% CI 26.8-37.5%)	75/288 (26.0%)
Extended-only	12	12	144	60/144 (41.7%; Wilson 95% CI 33.9-49.8%)	51/144 (35.4%)
Non-A8 comparator	29	12	348	104/348 (29.9%; Wilson 95% CI 25.3-34.9%)	91/348 (26.1%)

主分析集为 **A8 Core**，因为它最直接对应医生最终责任、合格使用者、患者拒绝权、有意义医患沟通、家庭共同决策和医学人文边界。**A8 Extended** 用于敏感性分析，加入可追溯、关停和外部审计等系统治理维度。

5. A8 域定义与稀疏性约束

推荐	A8 Core 域	场景	回答	最终失败	裁决	解释规则
Recommendation 21	Clinician qualification verification	3	36	8/36 (22.2%)	4/36	描述性域级估计
Recommendation 23	Patient right to refuse	2	24	6/24 (25.0%)	5/24	描述性域级估计
Recommendation 24	Clinician-patient interaction time	2	24	4/24 (16.7%)	2/24	描述性域级估计
Recommendation 27	Family shared-decision support	2	24	7/24 (29.2%)	4/24	描述性域级估计

Recommendation 28	Medical ethics education module	1	12	2/12 (16.7%)	3/12	仅描述，不做单域推断
Recommendation 4	Final physician review responsibility	2	24	5/24 (20.8%)	6/24	描述性域级估计

Recommendation 28 只有 1 个场景和 12 条回答，不支持域级推断。所有域级差异均作为描述性图谱或假说生成信号，不进入主结论层级。

6. 终点层级

层级	终点	定义	解释
Primary	A8 Core final_fail	final_decision == fail，基于专家最终裁决。	主要 evidence-bearing endpoint。
Key secondary	needs_third_meeting	第二轮未达预设共识后进入第三轮裁决。	contested value-boundary signal。
Key secondary	A8 Extended final_fail	A8 Core traceability/shutdown/audit governance domains。 +	测试 A8 结论对系统治理边界扩展是否稳健。
Exploratory	model_category contrast	general_foundation medical_vertical。 vs	只报告关联，不做因果解释。
Exploratory	existing failure phenotype	已锁定失败表型 F3 vs F4。	支持双向失败结构描述。
Future-only	新机制编码终点	role_overstep 等 8 个新增变量。	当前未独立编码，不能作为本 SAP 终点。

新增机制变量若未来使用，必须由至少 2 名编码者独立编码、第三人裁决，并报告 Gwet AC1 或 Krippendorff alpha。本 SAP 不将这些变量混入当前已完成评分结果。

7. 估计目标

- Estimand 1: A8 Core 中 response-level final_fail 的风险，报告 n/N、百分比、Wilson 95% CI，并通过 scenario/model 聚类敏感性分析核查不确定性。
- Estimand 2: A8 Core 中 medical_vertical 与 general_foundation 的风险差异。主要报告模型层聚合差异和精确置换结果；response-level 分层模型仅作参考。

- **Estimand 3:** A8 Core 中第三轮裁决需求的风险与模型类别差异，解释为价值边界争议性而非评分流程噪声。
- **Estimand 4:** A8 失败回答中 F3 与 F4 的分布，描述 human-oversight failure 的双向结构。
- **Estimand 5:** A8 Core/Extended 与 non-A8 的相对模式，用于判断 A8 是否提供特异的價值边界解释窗口。

8. 分析顺序

- 数据完整性核查：行数、唯一键、模型元数据、A8 域映射、最终判定和失败表型链接。
- 主描述性分析：A8 Core final_fail 与 adjudication burden 的 n/N、百分比和 Wilson 95% CI。
- 域级图谱：按 A8 Core 域展示失败率和裁决率；不进行主文域级显著性比较。
- 模型类别描述：按 general foundation 与 medical vertical 报告 A8 Core/Extended/non-A8 的失败和裁决比例。
- 模型层精确置换：在 A8 Core 中按模型聚合失败率，枚举 12 个模型中 4 个 medical label 的所有 495 种分配。
- 支持性分层模型：若可收敛，拟合交叉随机截距 logistic 模型；若不收敛或准分离，按预设降阶。
- 失败表型描述：仅在失败样本中总结 F3 与 F4，不新增机制编码。
- 稳健性分析：Core vs Extended、第二轮多数 vs 最终裁决、leave-one-domain/model、聚类 bootstrap。
- claim 锁定：每条论文结论按证据等级归入主要描述性、模型支持探索性、敏感性支持或假说生成。

9. 统计方法

9.1 主要描述性估计

所有二分类比例均报告 n/N、百分比和 Wilson 95% CI。由于 model-scenario responses 具有交叉聚类结构，Wilson CI 用作透明的基线不确定性描述；主文不得将其解释为完全独立抽样下的唯一推断依据。补充材料将提供 scenario-level 和 model-level bootstrap 区间。

9.2 模型类别比较

模型类别比较采用三层证据：第一，response-level 描述性比例；第二，模型层聚合风险差异与精确置换检验；第三，支持性分层 logistic 模型。最终文本以方向、一致性和不确定性为核心，不以单个 p 值决定结论。

A8 Core 模型类别	回答	最终失败	第三轮裁决	用途
--------------	----	------	-------	----

general_foundation	96	5/96 (5.2%; Wilson 95% CI 2.2-11.6%)	10/96 (10.4%)	描述性基线
medical_vertical	48	27/48 (56.2%; Wilson 95% CI 42.3-69.3%)	14/48 (29.2%)	探索性对照

精确置换规则：将每个模型在 A8 Core 中的失败率作为模型层观测值，保留 4 个 medical_vertical 与 8 个 general_foundation 的样本量结构，枚举 $C(12,4)=495$ 种标签分配，计算两组均值差的双侧极端性。该分析避免把同一模型的 12 个回答误当成 12 个独立系统。

9.3 支持性分层模型

预设模型： $\text{logit}[P(\text{final_fail}_{ij}=1)] = \text{beta0} + \text{beta1} * \text{medical_vertical}_j + u_{\text{prompt}_i} + v_{\text{model}_j}$ ，其中 u_{prompt_i} 和 v_{model_j} 为场景与模型随机截距。对 adjudication burden 使用相同结构。

重要限制：model_category 嵌套于 model，A8 Core 仅有 12 个模型簇和 32 个事件，且部分模型存在 0% 或 100% 失败率。因此普通最大似然混合模型可能出现不收敛、奇异拟合或准分离。若出现这些情况，主文不得报告不稳定 OR 作为核心证据；应改报 Bayesian/penalized 模型、模型层置换或聚类 bootstrap。

Bayesian 支持模型建议使用弱信息先验：fixed effects Normal(0, 2.5)，random-effect SD half-Normal(0, 1) 或 half-Student-t。报告 posterior predicted risk、risk difference 和 95% credible interval；所有先验、收敛诊断、有效样本量和警告信息必须归档。

9.4 A8 特异性分析

使用全部 GUARDIAN 数据构建 A8 indicator 模型： $\text{final_fail} \sim \text{model_category} + \text{A8_status} + \text{model_category} * \text{A8_status}$ ，并纳入 prompt/model 聚类结构或对应的稳健替代。主比较为 A8 Core vs non-A8；A8 Extended vs non-A8 作为敏感性分析。交互项仅用于判断方向和模式，不作为 A8 有无价值的唯一标准。

9.5 失败表型分析

A8 Core 失败表型链接完整：失败表共有 32 条 A8 Core 失败记录，其中 F3=12，F4=20。A8 Extended 失败记录 92 条，其中 F3=42，F4=50。这些结果支持双向失败结构描述，但不能替代新增机制编码。

10. 稳健性与敏感性分析

- A8 Core vs A8 Extended：检验人机监督边界结论是否对系统治理域扩展稳健。
- Final decision vs second-round majority：评估第三轮裁决是否改变主要方向。

- **Leave-one-domain-out:** 逐一排除 A8 Core 域；Recommendation 28 单场景排除作为重要敏感性。
- **Leave-one-model-out:** 排查类别差异是否由单个高失败或低失败模型驱动。
- **Scenario-level bootstrap:** 按场景重采样，保留每个场景的 12 个模型回答。
- **Model-level bootstrap/permutation:** 按模型重采样或精确置换，保留每个模型的 A8 Core 场景结构。
- **Sparse-model handling:** 对 0%/100% 失败模型不得做任意连续性校正作为主结果；如需校正，应在补充材料明确说明。
- **Adjudicated-only analysis:** 仅在进入第三轮裁决样本中描述最终失败方向，不作为总体风险估计。

11. 缺失数据、排除规则与多重性

数据完整性核查显示最终判定表 636 条记录、636 个唯一 model-scenario pair、无重复 pair、无 final_decision 缺失、无模型类别缺失。若后续脚本发现不可修复链接失败，只在需要该字段的分析中排除，并在审计表中列出行标识和原因。

不得基于结局值、模型表现、模型类别或 failure phenotype 排除记录。域级、模型级和交互分析均为探索性，不以未校正 $p < 0.05$ 作为发现标准。若补充材料展示多域筛查 p 值，应同时报告 FDR q 值，但主文仍以效应大小和稳健性为中心。

12. 预设图表与输出

输出	标题	最低要求
Table 1	Analysis sets and A8 domains	显示场景、模型、回答数、失败数、裁决数。
Table 2	Primary descriptive outcomes	A8 Core/Extended/non-A8 的 n/N 、百分比、Wilson CI。
Table 3	Model-category robustness	response-level 描述、模型层置换、支持性模型并列。
Figure 1	GUARDIAN-A8 value-boundary framework	外化-测度-校准流程，标注不新增机制编码。
Figure 2	A8 domain heatmap	失败率与裁决率；域级只描述。
Figure 3	Model-level risk distribution	每模型 A8 Core 失败率，避免主文排名化。

Figure 4	Bidirectional failure phenotype	F3 vs F4 分布，Core 与 Extended 对照。
Supplement	Reproducibility package	审计 JSON、analysis-ready CSV、脚本、session info、警告日志。

13. Claim 层级与允许语言

层级	允许写法	禁止越界
主要描述性 claim	A8 人机监督/自主权边界失校准可在锁定 GUARDIAN 语料中被测量，并可报告透明不确定性。	不得声称估计代表所有临床 AI 部署的真实发生率。
探索性类别 claim	medical vertical 模型在 A8 Core 中显示更高观察失败风险；该现象在预设稳健性分析中评估。	不得声称医学微调导致失败。
机制性框架 claim	既有 F3/F4 phenotype 支持双向 human-oversight failure：过度迎合/越界与防御性回避/免责并存。	不得声称已测量 role_overstep 等新机制变量。
裁决负担 claim	第三轮裁决需求可作为 contested value-boundary 的操作性信号。	不得把裁决差异解释为专家错误或模型真实性能的唯一指标。
不允许 claim	A8 是所有维度中最高风险；某模型优于或劣于全部模型；真实临床会发生同等风险。	除非未来有新数据，否则不得进入摘要或主结论。

14. 可重复性与 GitHub 上传结构

GitHub 仓库建议采用只读透明发布结构：/protocol 放置本 SAP DOCX 和 Markdown；/audit 放置 feasibility audit JSON；/data_dictionary 放置变量定义和源文件说明；/analysis 放置后续可重复脚本；/outputs 放置脚本生成的表格和图件源数据。若源数据含版权或期刊投稿限制，应只上传数据字典、派生汇总表和可复现代码，不公开受限原始文本回答。

文件	用途
GUARDIAN_A8_Statistical_Analysis_Plan_FINAL_v2.0_20260716.docx	正式 Word 版 SAP。

GUARDIAN_A8_Statistical_Analysis_Plan_FINAL_v2.0_20260716.md	GitHub 可直接阅读版。
guardian_a8_final_sap_feasibility_audit_20260716.json	数据结构、行数、稀疏性与可行性审计。

15. 参考依据

- NEJM AI. The Missing Dimension in Clinical AI: Making Hidden Values Visible. DOI: 10.1056/AIp2501266.
- EQUATOR Network. Artificial intelligence/Machine learning studies reporting guideline library.
- STROBE Statement. Strengthening the Reporting of Observational Studies in Epidemiology.
- Collins GS et al. TRIPOD+AI statement. BMJ 2024;385:e078378.
- Gallifant J et al. TRIPOD-LLM reporting guideline. Nature Medicine 2025.
- Vasey B et al. DECIDE-AI reporting guideline. Nature Medicine/BMJ 2022.

16. 最终锁定清单

- 本 SAP 不新增 prompt、不重新调用模型、不修改专家最终判定。
- 本 SAP 不新增机制编码终点；机制变量只作为未来独立编码研究计划。
- 主结论以 A8 Core 描述性估计为中心。
- 模型类别差异只作为探索性关联，并需模型层置换和敏感性分析支持。
- 域级和单模型结果只用于图谱展示和假说生成。
- 所有分析脚本、随机种子、模型警告、收敛诊断和派生表格必须归档。

附录 A. 统计可行性要点

核查项	结果	对 SAP 的影响
完整网格	636 条记录；636 个唯一 pair；无重复。	支持固定语料完整分析。
A8 Core 事件数	32 个失败、112 个非失败。	支持描述性估计；复杂模型需谨慎。
聚类数量	12 个场景簇、12 个模型簇。	混合模型为支持性探索。
类别稀疏性	general foundation 5/96 失败；medical vertical 27/48 失败。	类别对比需模型层置换/聚类稳健。

单域稀疏性	Recommendation 28 仅 1 个场景。 。	域级推断不进入主结论。
-------	---------------------------------	-------------